Guia de Estudo para a Apresentação

Classificação de dificuldade de palavras com seis modelos de aprendizado de máquina. Leia na ordem: seções 1 a 3 dão a base; 4 a 7 explicam o que foi feito; 8 e 9 preparam a demonstração e as perguntas da professora.

1. A ideia em um minuto

Problema: o aplicativo ensina leitura. Para montar exercícios, é preciso saber se uma palavra é **fácil**, **média** ou **difícil**. Classificar milhares de palavras à mão é inviável.

Solução: pessoas classificaram algumas centenas de palavras (os "gabaritos"). Seis algoritmos aprenderam, com esses exemplos, a relacionar características da palavra (sílabas, ditongo, tamanho, frequência…) com a dificuldade. O melhor algoritmo foi escolhido e aplicado às 7.649 palavras do corpus.

> "Fizemos aprendizado supervisionado: pessoas rotularam uma amostra, seis modelos aprenderam com ela, comparamos todos em palavras que eles nunca viram, e o melhor classificou o corpus inteiro."

2. Conceitos que você precisa dominar

Termo	Significado simples
Aprendizado supervisionado	O computador aprende a partir de exemplos já respondidos por humanos (palavra + dificuldade correta).
Rótulo (alvo)	A resposta correta que o modelo tenta prever: facil, medio ou dificil. Veio das avaliações humanas.
Atributos (features)	Números que descrevem cada palavra e servem de entrada para o modelo (ex.: nº de sílabas).
Treino / teste	Treino: palavras que o modelo vê para aprender. Teste: palavras guardadas, que ele nunca viu, para medir se aprendeu de verdade.
Estratificado	A divisão treino/teste mantém a mesma proporção de fáceis, médias e difíceis nos dois grupos.
Accuracy	Percentual de acertos. Ex.: 58 acertos em 68 palavras = 85,29%.
Macro-F1	Média da qualidade nas três classes, todas com o mesmo peso. Não deixa uma classe grande esconder erros em outra. É a métrica principal para escolher o vencedor.
Matriz de confusão	Tabela que mostra o que o modelo acertou e com qual classe confundiu cada erro.
Previsão x acerto real	Acerto real só existe onde há rótulo humano (as 68 palavras de teste). As 7.649 classificações do corpus são previsões.

Termos de linguística

Termo	Explicação e exemplo
Estrutura silábica	C = consoante, V = vogal. "casa" = CV-CV (simples). "prato" = CCV-CV (tem encontro).
Encontro consonantal	Duas consoantes juntas no início da sílaba: **pr**ato, **bl**usa.
Coda	Consoante no fim da sílaba: ma**r**, pa**s**ta. Estrutura CVC.

Termo	Explicação e exemplo
Ditongo	Duas vogais na mesma sílaba: pa**i**, bo**i**. No corpus aparece como G (semivogal).
Dígrafo	Duas letras para um som: ch, lh, nh, rr, ss, qu, gu.

3. Por que usamos avaliação humana

No começo, testamos uma classificação baseada só na estrutura silábica. O CART (árvore de decisão) tirou 100%. Isso **não** era mérito dele: o rótulo havia sido criado pelas mesmas regras que o modelo recebia como entrada, então ele apenas memorizou a regra. Isso se chama **circularidade**.

> "Descartamos esse experimento como resultado principal. Dificuldade pedagógica precisa vir de julgamento humano, e os atributos linguísticos entram só como entrada do modelo."

4. Passo a passo do que foi feito

Etapa	O que aconteceu	Resultado
1. Corpus	Usamos o corpus Santos–Toni tratado (versão final, vinda da branch main).	7.649 palavras distintas
2. Piloto	Três avaliadores classificaram as mesmas 30 palavras de forma independente, com uma rubrica escrita.	Calibrou critérios; divergências foram registradas
3. Consolidação do piloto	Mediana das três notas (fácil=1, médio=2, difícil=3). "domino" excluída por ambiguidade (verbo ou jogo).	29 palavras válidas
4. Avaliação ampliada	270 palavras novas, com sugestão prévia dos modelos; a pessoa dava o veredito final.	260 válidas, 10 excluídas (ruído, grafia errada, estrangeirismo)
5. Lote de fáceis	A classe fácil estava pequena; avaliamos 60 candidatas fáceis.	52 fáceis e 8 médias
6. Base final	Juntamos tudo: 349 rótulos. Casamos com o corpus final e removemos duplicidade por lema.	339 palavras: 94 fáceis, 141 médias, 104 difíceis
7. Atributos	Extraímos 11 números por palavra (seção 5).	Tabela numérica de entrada
8. Divisão	80% treino, 20% teste, estratificada, semente 7 (reprodutível).	271 treino, 68 teste
9. Seis modelos	Todos treinados e testados com o mesmo protocolo.	SVM vencedor
10. Corpus completo	Os seis foram treinados com as 339 palavras e aplicados às 7.649.	Previsões salvas em CSV e no banco
11. Salvamento	SVM, Regressão Logística e LDA salvos com joblib (padrão do notebook da professora).	Arquivos .joblib

5. Os 11 atributos usados

Grupo	Atributos
Estrutura silábica	Número de sílabas; sílabas complexas (diferentes de V, CV, CVV); encontros consonantais; maior padrão silábico; codas; ditongos/semivogais.

Grupo	Atributos
Ortografia	Tamanho da palavra; tem acento gráfico; dígrafos; grafemas complexos (x, ç).
Uso	Frequência no corpus em escala logarítmica (palavras muito frequentes não dominam a escala).

6. Os seis modelos e o resultado

Modelo	Accuracy	Macro-F1	Ideia intuitiva e por que foi bem/mal
SVM	85,29%	**85,73%**	Traça a fronteira com maior folga entre as classes. Lidou bem com atributos misturados. **Vencedor.**
Regressão Logística	85,29%	85,65%	Fronteira linear com probabilidades. Quase empate com o SVM: indica que a relação atributos→dificuldade é em grande parte linear.
LDA	79,41%	79,99%	Também linear, mas assume formato estatístico parecido entre classes; ficou abaixo.
KNN	75,00%	75,53%	Olha as palavras mais parecidas. Com poucos exemplos (271), faltam vizinhos confiáveis.
CART	73,53%	74,30%	Árvore de regras "se/então". Sensível a poucos exemplos; tende a decorar o treino.
Naive Bayes	52,94%	51,21%	Assume que os atributos são independentes. Aqui não são (palavra longa tem mais sílabas, codas, encontros…). Pior resultado.

Como o SVM foi escolhido: maior Macro-F1. Por que não só accuracy? Porque a base tem mais palavras médias (141) do que fáceis (94); accuracy sozinha pode favorecer a classe maior.

7. Resultado no banco de dados

Banco: **apps/api/alfabetiza.db** (SQLite). Foram criadas duas tabelas novas, sem mexer nas tabelas do aplicativo:

Tabela	Conteúdo
ml_experiment_runs	1 linha: palavras do corpus (7.649), rótulos humanos (339), treino (271), teste (68), modelo vencedor (SVM), accuracy e Macro-F1.
ml_word_predictions	7.649 linhas: palavra, estrutura silábica, frequência, previsão de cada um dos seis modelos, previsão selecionada (SVM) e concordância entre modelos (1 a 6).

Distribuição do SVM no corpus: **médio 3.648**, **difícil 3.509**, **fácil 492** (total 7.649).

Concordância: se os 6 modelos dão a mesma resposta, a palavra é "segura". Se discordam, é candidata a revisão humana.

8. Roteiro sugerido da apresentação (≈ 8 min)

Passo	O que falar / mostrar
1. Problema	Classificar dificuldade de palavras para o app de alfabetização.
2. Dados	Corpus de 7.649 palavras; só uma parte tem rótulo humano.

Passo	O que falar / mostrar
3. Avaliação humana	Piloto com 3 avaliadores, rubrica, rodadas ampliadas, exclusões. Base final: 339 palavras.
4. Atributos	Os 11 números por palavra (seção 5).
5. Protocolo	80/20 estratificado; teste de 68 palavras que o modelo nunca viu.
6. Resultados	Tabela dos seis modelos; SVM vencedor por Macro-F1; explicar por que NB foi pior.
7. Aplicação	Seis modelos aplicados às 7.649 palavras.
8. Banco (DBeaver)	Abrir ml_experiment_runs, depois ml_word_predictions. Mostrar uma palavra com 6 previsões e outra em que discordam.
9. Modelo salvo	Mostrar o notebook com joblib (treinar, salvar, carregar, prever).
10. Limitações	Falar sobre elas antes que perguntem (seção 9).

Consultas para o DBeaver: arquivo **ml/reports/consultas_dbeaver_apresentacao.sql**. Conexão: SQLite → arquivo apps/api/alfabetiza.db → tabelas ml_*.

9. Perguntas prováveis da professora e respostas

Por que SVM e não Regressão Logística, se empataram?

O SVM teve Macro-F1 ligeiramente maior (85,73% x 85,65%) e a mesma accuracy. Na prática é um empate técnico; a Regressão Logística é uma alternativa mais simples e interpretável, e por isso também foi salva.

O teste tem só 68 palavras. Isso é suficiente?

É pequeno: cada palavra a mais ou a menos muda cerca de 1,5 ponto percentual. Por isso as diferenças pequenas entre SVM e Regressão Logística não devem ser tratadas como definitivas. O resultado é uma primeira versão e a base pode ser ampliada.

Os rótulos são confiáveis?

No piloto, três avaliadores independentes e consolidação por mediana. Nas rodadas seguintes, os avaliadores viram uma sugestão prévia dos modelos e davam o veredito final, o que pode ter influenciado as respostas (viés de ancoragem). Isso é uma limitação e deve ser dita com honestidade.

Por que o resultado mudou de LDA para SVM?

Numa versão anterior usamos uma amostra balanceada de 282 palavras (94 por classe) com teste de 57; o LDA liderou. Ao usar todas as 339 palavras com divisão estratificada, o SVM passou a liderar. Isso mostra que, com amostra pequena, o vencedor é sensível à divisão dos dados — outro motivo para tratar LR e SVM como equivalentes.

Qual a taxa de acerto no corpus de 7.649 palavras?

Não é possível afirmar uma taxa para todo o corpus, pois só 339 palavras têm rótulo humano. A taxa medida (85,29%) vale para o conjunto de teste. Para o resto, são previsões.

O que é vazamento (leakage) e como evitaram?

É quando informação do teste vaza para o treino. Evitamos separando o teste antes de treinar, usando padronização dentro do pipeline de cada modelo e removendo duplicidade por lema (formas da mesma palavra não ficam em lados diferentes).

Por que normalizar (padronizar) os atributos?

SVM, KNN, Regressão Logística e LDA são sensíveis à escala: "frequência" e "número de sílabas" têm ordens de grandeza diferentes. A padronização coloca todos na mesma régua.

Por que o Naive Bayes foi o pior?

Ele supõe atributos independentes. Aqui são correlacionados (palavras longas tendem a ter mais sílabas, codas e encontros).

Por que não validação cruzada?

O resultado vem de uma única divisão 80/20, como pedido. Validação cruzada daria uma estimativa mais estável e é a melhoria natural, principalmente com base pequena.

Qual a utilidade prática?

Ordenar o conteúdo do aplicativo: começar por palavras fáceis e progredir. As palavras com baixa concordância entre modelos vão para revisão humana, e as correções humanas voltam como novos exemplos de treino.

10. Onde está cada coisa no projeto

Item	Caminho
Corpus final tratado	ml/data/Corpus_SANTOS_TONI_FDC_tratado_sem_repeticoes_final.xlsx
Rótulos humanos consolidados	ml/data/difficulty_labels_humanas_consolidadas.csv
Código do benchmark (6 modelos)	ml/src/alfabetiza_ml/benchmark_human_ratings.py
Código que salva os modelos	ml/src/alfabetiza_ml/train_and_save_human_models.py
Notebook (baseado no da professora)	ml/notebooks/salvar_modelos_lda_e_lr.ipynb
Modelos salvos	ml/artifacts/svm_, lr_ e lda_dificuldade_humana.joblib
Métricas completas	ml/reports/human_ratings_six_model_benchmark.json
Previsões do corpus	ml/reports/final_corpus_six_model_predictions.csv
Relatório de entrega	ml/reports/relatorio_final_classificacao_dificuldade_lexical.pdf
Banco para o DBeaver	apps/api/alfabetiza.db (tabelas ml_experiment_runs e ml_word_predictions)

11. Resumo para decorar

• 7.649 palavras no corpus; 339 com rótulo humano; 271 treino; 68 teste.
• 11 atributos linguísticos e ortográficos.
• Seis modelos, mesmo protocolo, semente 7.
• SVM venceu: 85,29% accuracy, 85,73% Macro-F1; Regressão Logística quase empatada; Naive Bayes pior (51,21%).
• Corpus classificado pelo SVM: médio 3.648, difícil 3.509, fácil 492.
• Acerto real = só no teste; o resto é previsão.
• Limitações: teste pequeno, viés possível nas sugestões prévias, divisão única.