Relatório Final — Classificação de Dificuldade Lexical

Comparação dos seis modelos obrigatórios de aprendizado de máquina para classificar palavras em **facil**, **medio** e **dificil**.

Resultado principal: no protocolo final reproduzível, o **SVM** foi o melhor modelo, com 85,29% de accuracy e 85,73% de Macro-F1.

1. Objetivo

O trabalho avalia qual algoritmo supervisionado reproduz melhor a dificuldade lexical atribuída por avaliadores humanos. A classificação foi feita a partir de propriedades linguísticas e ortográficas das palavras, sem criar o rótulo automaticamente a partir das mesmas regras usadas como entrada do modelo.

2. Corpus e rótulos humanos

Foi utilizado o corpus tratado final, com 7.649 palavras distintas. A base de referência foi construída a partir de: (a) piloto com três avaliadores independentes; (b) avaliação ampliada de 270 palavras, com 260 rótulos válidos; e (c) lote complementar de 60 candidatas fáceis, com 52 avaliadas como fáceis e 8 como médias. Itens com ruído, grafia inadequada, estrangeirismo, ambiguidade ou exclusão explícita não foram usados.

Foram consolidados 349 rótulos humanos. Após a correspondência com o corpus final e a remoção de duplicidades por lema, a base experimental ficou com 339 palavras: 94 fáceis, 141 médias e 104 difíceis.

3. Atributos usados para treinar os modelos

Grupo	Atributos
Estrutura silábica	Número de sílabas, quantidade de sílabas complexas, encontros consonantais, maior padrão silábico, codas e ditongos/semivogais.
Ortografia	Comprimento da palavra, presença de acentuação gráfica, dígrafos e grafemas complexos, como x e ç.
Uso no corpus	Frequência transformada por logaritmo para reduzir o efeito de valores extremos.

4. Protocolo de avaliação

Todos os modelos foram treinados com 80% das 339 palavras humanas e testados nas 20% restantes. A divisão foi estratificada e usou a semente aleatória 7, preservando a proporção das três classes. O conjunto de treino teve 271 palavras e o teste reservado teve 68 palavras.

A métrica principal foi o **Macro-F1**, pois atribui o mesmo peso às classes fácil, média e difícil. Accuracy foi apresentada como métrica complementar.

5. Modelos comparados

Sigla	Algoritmo	Papel
LR	Regressão Logística	Modelo linear probabilístico de referência.
LDA	Análise Discriminante Linear	Separação linear baseada na distribuição dos atributos.
KNN	K-vizinhos mais próximos	Classificação por proximidade aos exemplos humanos.
CART	Árvore de decisão	Regras condicionais interpretáveis.
NB	Gaussian Naive Bayes	Probabilidades sob hipótese de independência entre atributos.
SVM	Support Vector Machine	Fronteiras de decisão com maior margem entre classes.

6. Resultados no teste reservado

Modelo	Accuracy	Macro-F1	F1 fácil	F1 médio	F1 difícil
SVM	85.29%	85.73%	85.71%	81.48%	90.00%
LR	85.29%	85.65%	87.80%	80.77%	88.37%
LDA	79.41%	79.99%	82.05%	75.86%	82.05%
KNN	75.00%	75.53%	83.72%	66.67%	76.19%
CART	73.53%	74.30%	85.00%	64.00%	73.91%
NB	52.94%	51.21%	54.29%	19.35%	80.00%

7. Interpretação dos resultados

SVM: foi o vencedor por apresentar o maior Macro-F1. A margem de separação favoreceu a distinção entre os padrões linguísticos das três classes, sem depender de uma regra única e rígida.

Regressão Logística: teve performance praticamente empatada com o SVM. Isso indica que os atributos possuem forte separação linear e que o resultado não depende exclusivamente de um modelo complexo.

LDA: apresentou bom desempenho, mas inferior ao SVM e à Regressão Logística nesta execução. Continua salvo como modelo alternativo, pois é interpretável e adequado a problemas de classificação multiclasse.

KNN e CART: tiveram desempenho intermediário. O KNN é sensível à escassez de vizinhos humanos semelhantes; o CART pode variar mais quando pequenos grupos de palavras definem regras de corte.

Gaussian Naive Bayes: teve o pior desempenho. Seus atributos não são independentes na prática: comprimento, estruturas complexas, codas, encontros consonantais e grafia tendem a aparecer juntos. Essa hipótese limita o modelo.

8. Aplicação ao corpus final completo

Após a comparação, cada um dos seis modelos foi treinado com as 339 palavras humanas disponíveis e aplicado às 7.649 palavras do corpus final. Essa etapa produz previsões para o corpus; ela não deve ser interpretada como taxa de acerto real, pois as palavras do corpus completo não receberam rótulo humano individual.

Modelo	Fácil	Médio	Difícil
LR	465	3204	3980
LDA	308	3997	3344
KNN	747	3848	3054
CART	870	4189	2590
NB	4554	621	2474
SVM	492	3648	3509

As previsões completas, com uma coluna por modelo e uma coluna de concordância, estão disponíveis em `ml/reports/final_corpus_six_model_predictions.csv`.

9. Modelos salvos e reprodutibilidade

Foram salvos os modelos SVM, Regressão Logística e LDA com `joblib`. O notebook `ml/notebooks/salvar_modelos_lda_e_lr.ipynb` demonstra o ciclo solicitado pela professora: treinar, salvar, carregar e prever. O arquivo `ml/artifacts/modelos_dificuldade_humana_manifest.json` registra a origem dos dados, as 11 características e a composição da base de treinamento.

10. Limitações e conclusão

A dificuldade lexical tem componente subjetivo, por isso avaliações humanas foram necessárias. A base ainda pode ser ampliada e palavras com discordância entre os modelos devem ter prioridade em novas rodadas de avaliação. Mesmo com essa limitação, o experimento é reproduzível, usa teste reservado, compara todos os seis algoritmos exigidos e preserva o melhor modelo final. A recomendação para a entrega é apresentar o SVM como modelo vencedor e a Regressão Logística como alternativa praticamente equivalente.